

Trabalho Prático 1: Métodos Clássicos de Recuperação de Informação

Rafael Mendonça Duarte (NUSP: 16817608) and João Pedro Correia Caetano (NUSP: 16987067)

Instituto de Ciências Matemáticas e Computação – Universidade de São Paulo
`{rmduarte,joaopcaetanoc}@usp.br`

Abstract. Este trabalho implementa e avalia dois métodos clássicos de recuperação de informação — o Modelo Vetorial (TF-IDF com similaridade do cosseno) e o Modelo Probabilístico BM25 — sobre a coleção Cranfield (1400 documentos, 225 consultas, 1837 julgamentos de relevância). Quatro configurações de pré-processamento (combinando remoção de stopwords e stemming de Porter) foram comparadas para o Modelo Vetorial, e a configuração com remoção de stopwords e stemming (menor tamanho médio de documento, 104,4 tokens, e menor vocabulário, 6975 termos) obteve o melhor MAP em ambos os modelos, sendo adotada como padrão para as demais análises. Nessa configuração, o BM25 (MAP = 0,2885) superou o Modelo Vetorial (MAP = 0,2734) em todas as métricas agregadas, efeito atribuído à normalização de tamanho de documento controlada pelo parâmetro b . Um grid search do BM25 sobre $k_1 \in \{0,5; 1,2; 2,0\}$ e $b \in \{0; 0,75; 1\}$ identificou $k_1 = 2,0$, $b = 0,75$ como a melhor combinação (MAP = 0,2925). Análises complementares por consulta, de reformulação de consultas e de erros mostram que ambos os modelos compartilham a limitação fundamental de dependerem de sobreposição lexical exata, falhando sistematicamente diante de sinonímia e de julgamentos de relevância baseados em escopo temático.

Keywords: Recuperação de Informação · Modelo Vetorial · BM25 · Cranfield · Pré-processamento

1 Introdução

O estudo da recuperação da informação concerne o desenvolvimento de métodos para a recuperação de dados não estruturados de acordo com uma dada consulta: um sistema de recuperação busca, em uma coleção finita de dados, quais itens são relevantes para o usuário [1]. Entre as abordagens clássicas destacam-se o Modelo Vetorial, que representa documentos e consultas como vetores ponderados por TF-IDF, e o Modelo Probabilístico, cujo expoente mais utilizado é o BM25 [2]. Ambos dependem exclusivamente de sobreposição lexical, sem noção de significado, o que os torna um ponto de partida natural para entender a eficácia e os limites de métodos estatísticos de recuperação. A coleção Cranfield, composta por resumos técnicos de aerodinâmica com julgamentos de relevância manuais, é um dos primeiros e mais tradicionais *benchmarks* da área [3].

O objetivo deste trabalho é desenvolver, comparar e avaliar o Modelo Vetorial e o BM25 sobre a coleção Cranfield, usando métricas padrão de recuperação de informação, e investigar o efeito de diferentes configurações de pré-processamento, de parâmetros do BM25 e

Table 1. Estatísticas de pré-processamento por configuração.

Configuração	Tam. médio doc. (tokens)	Vocabulário
Sem remoção de stopwords, sem stemming	170,83	9723
Com remoção de stopwords, sem stemming	104,39	9605
Sem remoção de stopwords, com stemming	170,83	7085
Com remoção de stopwords, com stemming (padrão)	104,39	6975

de reformulações de consulta sobre a qualidade do ranking. O restante do relatório segue: Seção 2 descreve as técnicas, Seção 3 a metodologia de avaliação, Seção 4 os resultados experimentais, e Seção 5 as considerações finais.

2 Técnicas Utilizadas

2.1 Pré-processamento

O texto foi normalizado para minúsculas e tokenizado com o `word_tokenize` do NLTK. Quatro configurações foram comparadas, combinando (ou não) remoção de *stopwords* (lista padrão de inglês do NLTK) e *stemming* de Porter (`PorterStemmer`). A Tabela 1 resume o tamanho médio de documento (tokens) e o vocabulário resultante.

A remoção de stopwords reduz drasticamente o tamanho médio do documento (-39%), mas quase não altera o vocabulário, pois stopwords são poucos tipos de alta frequência. Já o stemming reduz fortemente o vocabulário ($\approx -27\%$) ao conflar variações morfológicas em um mesmo radical, sem afetar a contagem de tokens.

2.2 Modelo Vetorial

No Modelo Vetorial, documentos e consultas são representados como vetores no espaço dos termos do vocabulário, ponderados por TF-IDF. Usando o `TfidfVectorizer` do scikit-learn (tokenização por espaço em branco, pois o texto já chega pré-processado), cada peso é calculado como

$$\text{tfidf}(t, d) = \text{tf}(t, d) \cdot \left(\ln \frac{1 + N}{1 + \text{df}(t)} + 1 \right), \quad (1)$$

onde $\text{tf}(t, d)$ é a frequência bruta do termo t em d , N o número de documentos e $\text{df}(t)$ o número de documentos que contêm t (`use_idf=True`, `smooth_idf=True`, `sublinear_tf=False`). Cada vetor de documento é normalizado pela norma L2. A similaridade entre consulta q e documento d é o cosseno do ângulo entre seus vetores, $\cos(\mathbf{q}, \mathbf{d}) = \mathbf{q} \cdot \mathbf{d} / (\|\mathbf{q}\| \|\mathbf{d}\|)$, que, com os documentos normalizados, se reduz a um produto interno esparso, calculado para todos de uma vez via `cosine_similarity`. O ranking ordena os documentos por esse score em ordem decrescente.

2.3 Modelo Probabilístico — BM25

O BM25 foi implementado manualmente (sem bibliotecas externas), seguindo a formulação clássica do *framework* probabilístico de relevância [2]. O score de um documento D para uma consulta $Q = \{q_1, \dots, q_n\}$ é

$$\text{score}(D, Q) = \sum_{i=1}^n \text{IDF}(q_i) \cdot \frac{f(q_i, D) (k_1 + 1)}{f(q_i, D) + k_1 \left(1 - b + b \frac{|D|}{\text{avgdl}} \right)}, \quad (2)$$

Table 2. Métricas por configuração de pré-processamento (Vetorial) e BM25 na configuração padrão.

Configuração (modelo)	MAP	P@10	R@10	F1@10	MRR	NDCG@10
Vet. (-SW, -St)	0,2450	0,1996	0,3198	0,2230	0,4859	0,2829
Vet. (+SW, -St)	0,2495	0,2093	0,3383	0,2339	0,4824	0,2919
Vet. (-SW, +St)	0,2646	0,2169	0,3648	0,2454	0,5033	0,3072
Vet. (+SW, +St, padrão)	0,2734	0,2204	0,3682	0,2490	0,5133	0,3130
BM25 (padrão)	0,2885	0,2213	0,3697	0,2507	0,5249	0,3222

-SW/+SW: sem/com remoção de stopwords; -St/+St: sem/com stemming.

com o IDF de Robertson calculado, por termo, como $IDF(q_i) = \ln\left(\frac{N - df(q_i) + 0.5}{df(q_i) + 0.5} + 1\right)$, em que $f(q_i, D)$ é a frequência de q_i em D , $|D|$ o tamanho de D em tokens e $avgdl$ o tamanho médio dos documentos. k_1 controla a saturação da frequência de termo (valores altos deixam $f(q_i, D)$ crescer por mais tempo antes de saturar), enquanto $b \in [0, 1]$ controla a normalização por tamanho do documento ($b = 0$: sem normalização; $b = 1$: normalização completa). Os parâmetros *default*, salvo indicação contrária, são $k_1 = 1,2$ e $b = 0,75$.

3 Avaliação

O experimento utiliza a coleção Cranfield, obtida via `ir_datasets` [3]: 1400 documentos, 225 consultas e 1837 julgamentos de relevância (*qrels*). Cada *qrel* tem grau de 1 (interesse mínimo) a 4 (resposta completa), ou -1 (sem interesse); um documento é **relevante** se seu grau ≥ 1 , e não relevante caso contrário (grau -1 ou ausência de julgamento).

As métricas, calculadas por consulta e agregadas por média sobre as 225 consultas, são: P@10 e R@10 (fração de relevantes entre os 10 primeiros, e fração dos relevantes totais recuperada nos 10 primeiros); AP, cuja média define o MAP; F1@10, média harmônica de P@10 e R@10; RR (inverso da posição do primeiro relevante), cuja média define o MRR; e NDCG@10, que usa o grau graduado normalizado pelo DCG ideal. As configurações avaliadas foram: (i) as 4 configurações de pré-processamento no Modelo Vetorial; (ii) o BM25 padrão; (iii) um *grid search* 3×3 de (k_1, b) do BM25.

4 Resultados e Análise

4.1 Comparação de pré-processamento e entre modelos

A Tabela 2 mostra as métricas do Modelo Vetorial nas quatro configurações de pré-processamento e, na última linha, o BM25 na configuração padrão (destacada), permitindo comparar de uma só vez o efeito do pré-processamento e a diferença entre modelos.

A configuração com remoção de stopwords e stemming obteve o melhor MAP entre as quatro do Vetorial, sendo adotada como padrão. O stemming isoladamente traz o maior ganho (0,2450 $\rightarrow$ 0,2646 sozinho; 0,2495 $\rightarrow$ 0,2734 combinado): ao conflar variações morfológicas em um radical, aumenta a sobreposição exata entre termos, beneficiando precisão e revocação sem efeito colateral. A remoção de stopwords isolada traz ganho menor (0,2450 $\rightarrow$ 0,2495), mas é mais relevante combinada ao stemming. Nessa configuração padrão, o BM25 supera o Vetorial em todas as métricas, com margens modestas em P@10/R@10/F1@10 ($< 0,01$) e mais expressivas em MAP e NDCG@10 ($\approx 0,015$ e $0,009$). A explicação principal é a normalização por tamanho: o cosseno normaliza cada vetor pela

Table 3. Top-5 de cada modelo nas 6 consultas selecionadas.

Q.	Vetorial — Top-5	BM25 — Top-5
167	553, 1099, 1279, 1097, 1100	274✓, 553, 1279, 82✓, 1100
81	714, 652, 249, 799✓, 206	799✓, 714, 672✓, 631, 185
145	1045✓, 839✓, 763✓, 1046, 1051	1126, 1051, 827, 1045✓, 641
77	667✓, 1264, 668✓, 345, 329✓	1264, 630, 667✓, 272, 345
31	751, 68, 918, 247, 916	751, 1209, 1153, 1245, 1082
22	254, 125, 560, 140, 120	125, 560, 413, 254, 307

Table 4. MAP do BM25 por combinação (k_1, b) .

$k_1 \backslash b$	0	0,75	1
0,5	0,2588	0,2770	0,2762
1,2	0,2664	0,2885	0,2895
2,0	0,2682	0,2925	0,2909

norma L2 completa, podendo inflar a similaridade de documentos curtos que concentram seu peso TF-IDF em poucos termos (Seção 4.2); o BM25 usa o fator $1 - b + b|D|/\text{avgdl}$, calibrado por b , um controle mais gradual.

4.2 Análise por consulta

Seis consultas foram selecionadas pela diferença $\text{AP}_{\text{BM25}} - \text{AP}_{\text{Vetorial}}$ na config. padrão: as 2 com maior diferença positiva (BM25 muito superior: 167, 81), as 2 com diferença mais negativa (Vetorial muito superior: 145, 77), e as 2 com pior $\max(\text{AP}_{\text{vet}}, \text{AP}_{\text{bm25}})$ entre as 225 consultas (ambos insatisfatórios: 31, 22). A Tabela 3 traz o Top-5 de cada modelo (✓ = relevante).


Nas consultas 167 e 81 ($\text{AP}_{\text{Vet}} 0,108/0,268$ vs. $\text{AP}_{\text{BM25}} 0,750/0,833$), o relevante é relativamente longo (160 e 151 tokens) e contém o termo mais discriminativo (“ablat*” na 167; “tunnel”/“interference” na 81); no Vetorial fica fora do Top-5, enquanto documentos mais curtos (104 e 67 tokens) sobem ao topo. Hipótese: a normalização L2 divide pelo módulo do vetor do documento inteiro, e um documento curto concentra seu peso TF-IDF em poucos termos, inflando sua similaridade; o BM25 premia o termo raro no documento correto mesmo sendo mais longo que a média.

Nas consultas 145 e 77 ($\text{AP}_{\text{Vet}} 0,590/0,545$ vs. $\text{AP}_{\text{BM25}} 0,162/0,186$) o padrão se inverte: o relevante da 145 é curto (18 tokens) com *match* exato em três termos (“bend”, “pressur”, “cylind”); o cosseno o coloca em 1º, mas o BM25 em 4º, atrás de um não relevante 3,4× mais longo. Como o BM25 soma contribuições independentes por termo, documentos longos têm mais chance de conter *algum* termo da consulta multi-termo; o cosseno recompensa a concentração temática do documento curto.

Nas consultas 31 e 22 o único relevante fica na segunda metade do ranking em ambos os modelos (doc 776: rank 1350/1400 Vet., 1375/1400 BM25; doc 68: rank 989/1400 e 1042/1400). Não há sobreposição lexical: a consulta 31 pergunta sobre “end plate”/“aspect ratio”, e o documento relevante fala em “cilindros quadrados e dodecagonais” sem citar esses termos — mismatch de vocabulário que nenhum modelo lexical resolve.

4.3 Variação de parâmetros do BM25

A Tabela 4 traz o MAP do grid $k_1 \in \{0,5; 1,2; 2,0\} \times b \in \{0; 0,75; 1\}$ na config. padrão.

**Fig. 1.** MAP do BM25 por (k_1, b) (config. padrão).**Table 5.** Sobreposição do Top-10 entre consulta original e modificada.

Q.	Estratégia	Vet. (comuns/10)	BM25 (comuns/10)
31	Generalização (remove “cylindrical”)	9	8
167	Remoção de termos (compressão)	8	7
145	Sinônimo (<i>cylinders</i> → <i>shells</i>)	3	5
100	Especialização (acrécimo de qualificadores)	9	8
50	Remoção de termos + generalização	5	3

Fixando k_1 , $b = 0$ é sempre nitidamente pior que $b = 0,75$ ou $b = 1$ (ex.: $k_1 = 1,2$: MAP cai de 0,2885 para 0,2664, -8%); $b = 0,75$ e $b = 1$ ficam próximos entre si (diferença $< 0,002$). Fixando b , aumentar k_1 de 0,5 para 2,0 melhora o MAP consistentemente (ex.: $b = 0,75$: $0,2770 \rightarrow 0,2885 \rightarrow 0,2925$): como a coleção tem resumos curtos e técnicos, a repetição de um termo tende a ser sinal genuíno de foco temático, e k_1 maior deixa essa frequência contribuir por mais tempo antes de saturar. A melhor combinação é $k_1 = 2,0$, $b = 0,75$ (MAP = 0,2925); a pior é $k_1 = 0,5$, $b = 0$ (MAP = 0,2588).

Na consulta 124 (Top-10 mais alterado por b , $k_1 = 1,2$ fixo, só 2 documentos em comum entre os extremos), o Top-10 com $b = 0$ tem documentos de 201,6 tokens em média — quase o dobro de $\text{avgdl} \approx 104,4$ — caindo para 78,0 tokens com $b = 1$. Confirma-se o esperado: sem normalização, documentos longos vencem por acumular mais ocorrências brutas; com normalização plena, documentos mais curtos que a média são favorecidos. Nenhuma das variantes traz os 4 relevantes desta consulta ao Top-10.

4.4 Modificação de consultas

Cinco consultas foram reformuladas manualmente (sem uso dos qrels), com estratégias de generalização, remoção/compressão de termos, sinônimo e especialização. A Tabela 5 mostra quantos dos 10 documentos do Top-10 permanecem os mesmos entre original e modificada.

A troca por sinônimo (145) foi a mais disruptiva: no BM25, os relevantes no Top-10 caem de 2 para 0; no Vetorial, de 4 para 3. Isso ilustra a limitação central de modelos lexicais: “cylinder”/“shell” são sinônimos no domínio, mas após o stemming viram radicais

distintos, e a troca é tratada como outro conceito. O BM25 é mais frágil a essa perda — seu score soma contribuições independentes por termo — enquanto o cosseno redistribui o peso entre os termos restantes. Remover/acrescentar qualificadores genéricos (31, 100) tem efeito pequeno (8–9/10 preservados), por serem termos de baixo IDF. Remover um termo de conteúdo raro (50, “slender”) tem efeito intermediário e mais forte no BM25 (7/10 alterados) que no Vetorial (5/10), pelo mesmo motivo.

4.5 Análise de erros

Os falsos positivos exigem grau -1 explícito (não só ausência de julgamento) no rank 1 de *ambos* os modelos, evitando o efeito de *pooling* do Cranfield. Na consulta 3 (“heat conduction in composite slabs”), o doc. 485 (“linear heat flow in a composite slab”) tem sobreposição quase perfeita (*heat, composite, slab*) mas foi julgado não relevante: a consulta pede um panorama de problemas resolvidos, o documento trata um caso específico — diferença de escopo que nenhuma medida lexical capta. Na consulta 6, o doc. 491 compartilha vocabulário forte (*turbulent, couette, flow*) mas compara o perfil do Couette a outro escoamento via lei de potência, sem fornecer os “guias” amplos pedidos — mesmo problema de escopo. Como falso negativo, a consulta 124 (Seção 4.3) é, na prática, duas perguntas em uma; seu relevante mais próximo do Top-10 (doc. 967, rank 131–133/1400) compartilha vocabulário só com a primeira metade (*compressible, viscous, flow*), e sua pontuação é diluída por não casar com a segunda metade da consulta.

5 Considerações Finais

O BM25 superou o Vetorial em todas as métricas agregadas na configuração padrão, com vantagem mais clara quando o relevante é mais longo que a média (normalização por b); o Vetorial se saiu melhor com relevante curto e tematicamente concentrado. A configuração mais efetiva combinou remoção de stopwords e stemming (-28% de vocabulário, sem custo de desempenho). No grid do BM25, $b > 0$ foi necessário e $k_1 = 2,0$, $b = 0,75$ obteve o melhor MAP. Reformulação e erros convergem: ambos os modelos, puramente lexicais, falham diante de sinonímia e de julgamentos baseados em escopo. Limitações: tamanho pequeno e domínio específico da coleção. Extensões: expansão de consulta e modelos neurais (*dense retrieval*) como *baseline*.

6 Uso de Ferramentas de IA

O assistente de IA Claude (Anthropic) foi utilizado como apoio à programação/depuração do pré-processamento, do Vetorial e do BM25, à explicação de conceitos de RI e à escrita/formatação deste relatório. Decisões de projeto e interpretação dos resultados foram de responsabilidade dos autores.

References

1. Manning, C.D., Raghavan, P., Schütze, H.: Intro. to Information Retrieval. Cambridge Univ. Press (2008)
2. Robertson, S., Zaragoza, H.: The Probabilistic Relevance Framework: BM25 and Beyond. Found. Trends Inf. Retr. **3**(4), 333–89 (2009)
3. ir_datasets Documentation — Cranfield. <https://ir-datasets.com/cranfield.html>
4. NLTK Project: Natural Language Toolkit Documentation. <https://www.nltk.org/>
5. scikit-learn Developers: TfidfVectorizer — API Reference. https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.TfidfVectorizer.html