

Trabalho Prático 1: Métodos Clássicos de Recuperação de Informação

Rafael Mendonça Duarte (NUSP: 16817608) and João Pedro Correia Caetano (NUSP: 16987067)

Instituto de Ciências Matemáticas e Computação – Universidade de São Paulo
`{rmduarte,joaopcaetanoc}@usp.br`

Abstract. Este trabalho implementa e avalia dois métodos clássicos de recuperação de informação: o Modelo Vetorial (TF-IDF com similaridade do cosseno) e o Modelo Probabilístico BM25; sobre a coleção Cranfield (1400 documentos, 225 consultas, 1837 julgamentos de relevância). Quatro configurações de pré-processamento foram comparadas para o Modelo Vetorial, e a configuração com remoção de stopwords e stemming obteve o melhor MAP em ambos os modelos, sendo adotada como padrão para as demais análises. Nessa configuração, o BM25 (MAP = 0,2885) superou o Modelo Vetorial (MAP = 0,2734) em todas as métricas agregadas, efeito atribuído à normalização de tamanho de documento controlada pelo parâmetro b . Um grid search do BM25 sobre $k_1 \in \{0,5; 1,2; 2,0\}$ e $b \in \{0; 0,75; 1\}$ identificou $k_1 = 2,0$, $b = 0,75$ como a melhor combinação (MAP = 0,2925). Análises complementares por consulta, de reformulação de consultas e de erros mostram que ambos os modelos compartilham a limitação fundamental de dependerem de sobreposição lexical exata, falhando sistematicamente diante de sinonímia e de julgamentos de relevância baseados em contexto e semântica. Código disponível em <https://github.com/rduarte12/information-retrieval-1>.

Keywords: Recuperação de Informação · Modelo Vetorial · BM25 · Cranfield

1 Introdução

O estudo da recuperação da informação concerne o desenvolvimento de métodos para a recuperação de dados não estruturados de acordo com uma dada consulta: um sistema de recuperação busca, em uma coleção finita de dados, quais itens são relevantes para o usuário [1]. Entre as abordagens clássicas destacam-se o Modelo Vetorial, que representa documentos e consultas como vetores ponderados por TF-IDF, e o Modelo Probabilístico, neste trabalho representado por BM25 [2]. Ambos dependem exclusivamente de sobreposição lexical, sem noção de significado, semântica e contexto. A coleção Cranfield, composta por resumos técnicos de aerodinâmica com julgamentos de relevância manuais, é o *benchmark* [3] utilizado neste trabalho.

O objetivo deste trabalho é desenvolver, comparar e avaliar o Modelo Vetorial e o BM25 sobre a coleção Cranfield, usando métricas padrão de recuperação de informação, e investigar o efeito de diferentes configurações de pré-processamento, de parâmetros do BM25 e de reformulações de consulta sobre a qualidade do ranking. O restante do relatório segue: Seção 2 descreve as técnicas, Seção 3 a metodologia de avaliação, Seção 4 os resultados experimentais, e Seção 5 as considerações finais.

Table 1. Estatísticas de pré-processamento por configuração.

Configuração	Tam. médio doc. (tokens)	Vocabulário
Sem remoção de stopwords, sem stemming	170,83	9723
Com remoção de stopwords, sem stemming	104,39	9605
Sem remoção de stopwords, com stemming	170,83	7085
Com remoção de stopwords, com stemming (padrão)	104,39	6975

2 Técnicas Utilizadas

2.1 Pré-processamento

O texto foi normalizado para minúsculas e tokenizado com o `word_tokenize` do NLTK. Quatro configurações foram comparadas, combinando (ou não) remoção de *stopwords* (lista padrão de inglês do NLTK) e *stemming* de Porter (`PorterStemmer`). A Tabela 1 resume o tamanho médio de documento (tokens) e o vocabulário resultante.

A remoção de stopwords reduziu o tamanho médio do documento, mas quase não altera o vocabulário. Nota-se que as stopwords são poucas palavras, mas que possuem alta frequência. Contudo, o stemming reduziu o vocabulário, pois conflui variações morfológicas em um mesmo radical (exemplo: "correr", "corria", "correndo" -> "corr"), sem afetar a contagem de tokens.

2.2 Modelo Vetorial

No Modelo Vetorial, documentos e consultas são representados como vetores no espaço dos termos do vocabulário, ponderados por TF-IDF. Usando o `TfidfVectorizer` do scikit-learn, cada peso é calculado como

$$\text{tfidf}(t, d) = \text{tf}(t, d) \cdot \left(\ln \frac{1 + N}{1 + \text{df}(t)} + 1 \right), \quad (1)$$

onde $\text{tf}(t, d)$ é a frequência bruta do termo t em documento d , N o número de documentos e $\text{df}(t)$ o número de documentos que contêm t (`use_idf=True`, `smooth_idf=True`, `sublinear_tf=False`). Cada vetor de documento é normalizado pela norma L2. A similaridade entre consulta q e documento d é o cosseno do ângulo entre seus vetores, $\cos(\mathbf{q}, \mathbf{d}) = \mathbf{q} \cdot \mathbf{d} / (\|\mathbf{q}\| \|\mathbf{d}\|)$, que, com os documentos normalizados, se reduz a um produto interno esparsos, calculado para todos de uma vez via `cosine_similarity`. O ranking ordena os documentos por esse score em ordem decrescente.

2.3 Modelo Probabilístico (BM25)

O BM25 foi implementado manualmente, seguindo a formulação clássica do *framework* probabilístico de relevância [2]. O score de um documento D para uma consulta $Q = \{q_1, \dots, q_n\}$ é

$$\text{score}(D, Q) = \sum_{i=1}^n \text{IDF}(q_i) \cdot \frac{f(q_i, D) (k_1 + 1)}{f(q_i, D) + k_1 \left(1 - b + b \frac{|D|}{\text{avgdl}} \right)}, \quad (2)$$

Table 2. Métricas por configuração de pré-processamento (Vetorial) e BM25 na configuração padrão.

Configuração (modelo)	MAP	P@10	R@10	F1@10	MRR	NDCG@10
Vet. (−SW, −St)	0,2450	0,1996	0,3198	0,2230	0,4859	0,2829
Vet. (+SW, −St)	0,2495	0,2093	0,3383	0,2339	0,4824	0,2919
Vet. (−SW, +St)	0,2646	0,2169	0,3648	0,2454	0,5033	0,3072
Vet. (+SW, +St, padrão)	0,2734	0,2204	0,3682	0,2490	0,5133	0,3130
BM25 (padrão)	0,2885	0,2213	0,3697	0,2507	0,5249	0,3222

−SW/+SW: sem/com remoção de stopwords; −St/+St: sem/com stemming.

com o IDF de Robertson calculado, por termo, como $IDF(q_i) = \ln\left(\frac{N - df(q_i) + 0.5}{df(q_i) + 0.5} + 1\right)$, em que $f(q_i, D)$ é a frequência de q_i em D , $|D|$ o tamanho de D em tokens e avgdl o tamanho médio dos documentos. k_1 controla a saturação da frequência de termo (valores altos deixam $f(q_i, D)$ crescer por mais tempo antes de saturar), enquanto $b \in [0, 1]$ controla a normalização por tamanho do documento ($b = 0$: sem normalização; $b = 1$: normalização completa). Os parâmetros *default*, salvo indicação contrária, são $k_1 = 1,2$ e $b = 0,75$.

3 Avaliação

O experimento utiliza a coleção Cranfield, obtida via `ir_datasets` [3]: 1400 documentos, 225 consultas e 1837 julgamentos de relevância (*qrels*). Cada qrel tem grau de 1 (interesse mínimo) a 4 (resposta completa), ou −1 (sem interesse); um documento é **relevante** se seu grau ≥ 1 , e não relevante caso contrário (grau −1 ou ausência de julgamento). O texto utilizado do dataset foi capturado por meio do método `.docs_iter()` e as queries por `.queries_iter()`.

As métricas, calculadas por consulta e agregadas por média sobre as 225 consultas, são: P@10 e R@10 (fração de relevantes entre os 10 primeiros, e fração dos relevantes totais recuperada nos 10 primeiros); AP, cuja média define o MAP; F1@10, média harmônica de P@10 e R@10; RR (inverso da posição do primeiro relevante), cuja média define o MRR; e NDCG@10, que usa o grau graduado normalizado pelo DCG ideal. As configurações avaliadas foram: (i) as 4 configurações de pré-processamento no Modelo Vetorial; (ii) o BM25 padrão; (iii) um *grid search* 3×3 de (k_1, b) do BM25.

4 Resultados e Análise

4.1 Comparação de pré-processamento e entre modelos

A Tabela 2 apresenta um estudo de ablação, mostrando as métricas do Modelo Vetorial nas quatro configurações de pré-processamento e, na última linha, o BM25 na configuração padrão (destacado).

A configuração com remoção de stopwords e stemming obteve o melhor MAP entre as quatro do Vetorial, sendo adotada como padrão. O stemming isoladamente traz o maior ganho (0,2450 $\rightarrow$ 0,2646 sozinho; 0,2495 $\rightarrow$ 0,2734 combinado): nota-se que por confluir variações morfológicas em um radical, aumenta a sobreposição entre termos e a eficácia desses métodos de recuperação baseados em termos exatos. A remoção de stopwords isolada traz ganho menor (0,2450 $\rightarrow$ 0,2495). Nessa configuração padrão, o BM25 supera o Vetorial em todas as métricas, com margens menores em P@10/R@10/F1@10 ($< 0,01$) e mais expressivas

Table 3. Top-5 de cada modelo nas 6 consultas selecionadas.

Q.	Vetorial — Top-5	BM25 — Top-5
167	553, 1099, 1279, 1097, 1100	274✓, 553, 1279, 82✓, 1100
81	714, 652, 249, 799✓, 206	799✓, 714, 672✓, 631, 185
145	1045✓, 839✓, 763✓, 1046, 1051	1126, 1051, 827, 1045✓, 641
77	667✓, 1264, 668✓, 345, 329✓	1264, 630, 667✓, 272, 345
31	751, 68, 918, 247, 916	751, 1209, 1153, 1245, 1082
22	254, 125, 560, 140, 120	125, 560, 413, 254, 307

em MAP e NDCG@10 ($\approx 0,015$ e $0,009$). O principal indicativo para essa superioridade, ainda que modesta, do BM25, é a normalização por tamanho de documento, que ocorre de forma diferente quando comparado ao modelo vetorial. O BM25 usa o fator $1 - b + b|D|/\text{avgdl}$, calibrado por b . Já o modelo vetorial aplicado com similaridade por cosseno, normaliza cada vetor pela norma L2, aproximando documentos de circunstâncias diferentes a mesma magnitude.

4.2 Análise por consulta

Seis consultas foram selecionadas pela diferença $AP_{BM25} - AP_{Vetorial}$ na configuração padrão: as 2 com maior diferença positiva (BM25 superior: 167, 81), as 2 com diferença mais negativa (Vetorial superior: 145, 77), e as 2 com pior $\max(AP_{vet}, AP_{bm25})$ entre as 225 consultas (ambos insatisfatórios: 31, 22). A Tabela 3 traz o Top-5 de cada modelo (✓ = relevante).

Nas consultas 167 e 81 ($AP_{Vet} 0,108/0,268$ vs. $AP_{BM25} 0,750/0,833$), o relevante é relativamente longo (160 e 151 tokens) e contém o termo mais discriminativo (“ablat*” na 167; “tunnel”/“interference” na 81); no Vetorial fica fora do Top-5, enquanto documentos mais curtos (104 e 67 tokens) sobem ao topo. Hipótese: a normalização L2 divide pelo módulo do vetor do documento inteiro, e um documento curto concentra seu peso TF-IDF em poucos termos, inflando sua similaridade; o BM25 premia o termo raro no documento correto mesmo sendo mais longo que a média.

Nas consultas 145 e 77 ($AP_{Vet} 0,590/0,545$ vs. $AP_{BM25} 0,162/0,186$) o padrão se inverte: o relevante da 145 é curto (18 tokens) com *match* exato em três termos (“bend”, “pressur”, “cylind”); o cosseno o coloca em 1º, mas o BM25 em 4º, atrás de um não relevante 3,4× mais longo. Como o BM25 soma contribuições independentes por termo, documentos longos têm mais chance de conter *algum* termo da consulta multi-termo; o cosseno recompensa a concentração temática do documento curto.

Nas consultas 31 e 22 o único relevante fica na segunda metade do ranking em ambos os modelos (doc 776: rank 1350/1400 Vet., 1375/1400 BM25; doc 68: rank 989/1400 e 1042/1400). Não há sobreposição lexical: a consulta 31 pergunta sobre “end plate”/“aspect ratio”, e o documento relevante fala em “cilindros quadrados e dodecaedrais” sem citar esses termos.


4.3 Variação de parâmetros do BM25

A Tabela 4 traz o MAP do grid $k_1 \in \{0,5; 1,2; 2,0\} \times b \in \{0; 0,75; 1\}$ na config. padrão.

Fixando k_1 , $b = 0$ é pior que $b = 0,75$ ou $b = 1$ e, por outro lado, $b = 0,75$ e $b = 1$ ficam próximos entre si. Fixando b , aumentar k_1 de 0,5 para 2,0 melhora o MAP consistentemente. Isso indica que nessa coleção, a repetição de um termo tende a ser um sinal de relevância, e k_1 maior deixa essa frequência contribuir por mais tempo antes de saturar. A melhor combinação é $k_1 = 2,0$, $b = 0,75$ (MAP = 0,2925); a pior é $k_1 = 0,5$, $b = 0$ (MAP = 0,2588).

Table 4. MAP do BM25 por combinação (k_1, b) .

$k_1 \backslash b$	0	0,75	1
0,5	0,2588	0,2770	0,2762
1,2	0,2664	0,2885	0,2895
2,0	0,2682	0,2925	0,2909

**Fig. 1.** MAP do BM25 por (k_1, b) (config. padrão).

4.4 Modificação de consultas

Cinco consultas foram reformuladas manualmente, com a seguinte estratégia: generalização (retirada de especificidades), remoção de termos, sinônimo e acréscimo de termos (acrécimo de especificidades). A Tabela 6 mostra, para cada consulta e modelo, quantos dos documentos relevantes permanecem no Top-10 antes e depois da reformulação.

O experimento de reformulação das consultas explicita a limitação de ambos os modelos: a dependência de sobreposição lexical exata para recuperar documentos relevantes. Ademais que sejam tomadas diferentes estratégias para reformulação de consultas, como demonstrado na Tabela 5, um desconhecimento do vocabulário do domínio ou a ausência de termos discriminativos na consulta podem levar a uma perda de desempenho, como demonstrado na Tabela 6.

4.5 Análise de erros

Os dois falsos positivos identificados compartilham o mesmo padrão: sobreposição lexical alta com a consulta, mas diferença de escopo no conteúdo. Na consulta 3 (“heat conduction in composite slabs”), o documento 485 retorna na primeira posição de ambos os modelos por conter os termos da consulta, porém não aborda o escopo da consulta (consulta e texto abordam contextos diferentes). O mesmo ocorre na consulta 6: o documento 491 compartilha vocabulário relevante com a consulta, porém discute a relação entre o escoamento de Couette e o escoamento pressurizado e a consulta pede guias teóricos e experimentais sobre o tema.

O falso negativo ocorre na consulta 124, que formula dois problemas distintos em uma única sentença. O documento relevante mais próximo do Top-10 (documento 967, posição 131) cobre apenas a primeira parte da consulta. Como seu vocabulário não casa com a segunda parte, o score é diluído e o documento não sobe no ranking.

Table 5. Consultas reformuladas: texto original vs. modificado.

Q.	Estratégia	Original → Reformulada
31	Generalização	“...bluff cylindrical body...” → “...bluff body...”
167	Remoção de termos	“exact solution methods for calculating the ablative mass loss...” → “the ablative mass loss...”
145	Sinônimo	“...pressurized cylinders in bending.” → “...pressurized shells in bending.”
100	Especialização	“...effects of initial imperfections on the elastic buckling of cylindrical shells...” → “...effects of small initial geometric imperfections... thin cylindrical shells...”
50	Remoção + generalização	“...effects of small amounts of gas rarefaction... slender bodies of revolution.” → “...effects of gas rarefaction... bodies of revolution.”

Table 6. Documentos relevantes no Top-10, antes e depois da reformulação.

Q.	Estratégia	Vetorial		BM25	
		Orig.	Mod.	Orig.	Mod.
31	Generalização	0	0	0	0
167	Remoção de termos	1	1	2	2
145	Sinônimo	4	3	2	0
100	Especialização	2	2	3	2
50	Remoção + generalização	1	1	1	1

5 Considerações Finais

O BM25 tem resultados competitivos perante o modelo Vetorial nos experimentos realizados na base analisada. O modelo probabilístico demonstra ter vantagem quando o relevante é mais longo que a média (normalização por b). Já o Vetorial se saiu melhor com relevante curto e tem uma concentração de termos relevantes para a consulta. Sobre o que tange o pré-processamento, a configuração mais efetiva combinou remoção de stopwords e stemming. No grid do BM25, $b > 0$ foi necessário e $k_1 = 2,0$, $b = 0,75$ obteve o melhor MAP. Reformulação e erros convergem: ambos os modelos, puramente lexicais, falham em compreender a semântica dos documentos. Nota-se que pelo trabalho limitar-se a uma coleção pequena e de domínio específico, os resultados não podem ser generalizados para outros domínios.

6 Uso de Ferramentas de IA

Inteligência Artificial no que tange ao código, foi utilizada como apoio à depuração, especialmente na correção da implementação do BM25 e na geração dos gráficos. Também foi utilizada para auxiliar na construção de tabelas e correção de formatação no LaTeX.

References

1. Manning, C.D., Raghavan, P., Schütze, H.: Intro. to Information Retrieval. Cambridge Univ. Press (2008)
2. Robertson, S., Zaragoza, H.: The Probabilistic Relevance Framework: BM25 and Beyond. Found. Trends Inf. Retr. **3**(4), 333–89 (2009)
3. ir_datasets Documentation — Cranfield. <https://ir-datasets.com/cranfield.html>
4. NLTK Project: Natural Language Toolkit Documentation. <https://www.nltk.org/>
5. scikit-learn Developers: TfidfVectorizer — API Reference. https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.TfidfVectorizer.html